

# Rapport final de synthèse EDA

## Système de Prédiction de Loyer — Burundi

MEDIABOX Burundi

### 1. Contexte et objectif

Ce document synthétise les conclusions de l'*Exploratory Data Analysis* (EDA) et formalise les décisions à appliquer dans les phases suivantes du projet : **Data Preparation**, **Feature Engineering** et **Modélisation**.

L'objectif métier est de construire un modèle de régression capable de prédire le **LoyerMensuel\_BIF** d'une maison à Bujumbura à partir de ses caractéristiques physiques et de sa localisation.

### 2. Analyse de la variable cible : LoyerMensuel\_BIF

#### Observations :

- Distribution asymétrique à droite ( $\text{skewness} = 0.59$ ), avec des loyers élevés tirant la moyenne vers le haut.
- Présence d'un plafonnement artificiel : pic massif à 2 500 000 BIF. Ces valeurs semblent probablement saisies sous forme abrégée (par exemple "2.5M").
- La transformation logarithmique (`np.log1p`) améliore fortement la normalité de la distribution pour la majorité des valeurs ( $\text{skewness}$  passant à  $-0.57$ ).

#### Décision et action (Data Prep) :

- Supprimer les lignes où `LoyerMensuel_BIF == 2500000` afin d'éviter un biais sur les logements de luxe.
- Appliquer `np.log1p()` à la variable cible  $y$  avant l'entraînement.
- Convertir les prédictions finales en BIF avec `np.expml()` dans l'application Streamlit.

### 3. Analyse des variables numériques

#### 3.1. Chambres

#### Observations :

- Distribution symétrique de 1 à 6 chambres.
- Classes bien équilibrées.
- Aucun outlier détecté.
- Corrélation quasi parfaite avec `Superficie_m2` (0.98), ce qui révèle une redondance forte pour les modèles linéaires.

#### Décision et action :

- Conserver la variable au départ et valider son apport empiriquement pendant la phase de modélisation.

- En présence d'un modèle linéaire sensible à la multicollinéarité, réévaluer l'intérêt de la variable à l'aide d'une comparaison avec et sans Chambres.

### 3.2. Superficie\_m2

#### Observations :

- Distribution uniforme de 30 m<sup>2</sup> à 320 m<sup>2</sup>.
- Aucun outlier.
- Variable numérique la plus informative, avec une corrélation de 0.62 avec le loyer.

#### Décision et action :

- Conserver la variable.
- Appliquer un StandardScaler dans le pipeline de prétraitement.

### 3.3. DistanceRoute\_m

#### Observations :

- Distribution symétrique bornée de 0 à 300 m.
- Pic marqué à 300 m, suggérant un plafonnement.
- Relation non linéaire avec le loyer (corrélation de 0.02).

#### Décision et action :

- Conserver la variable.
- L'information géographique pourra être exploitée par des modèles d'arbres (Random Forest, Gradient Boosting).
- Appliquer un StandardScaler.

### 3.4. AgeMaison

#### Observations :

- Distribution symétrique de 0 à 40 ans.
- Pic marqué à 40 ans, suggérant un plafonnement.
- Relation non linéaire avec le loyer (corrélation de 0.02).

#### Décision et action :

- Conserver la variable.
- Appliquer un StandardScaler.

## 4. Analyse des variables catégorielles

### 4.1. Variables binaires : Salon, SalleDeBainInterieure, Parking, Meuble, Jardin

#### Observations :

- Salon, Jardin et SalleDeBainInterieure exercent un impact très fort sur le loyer : les médianes sont nettement plus élevées en présence de ces équipements.

- Parking présente un impact faible : les boîtes de médiane sont quasi identiques entre "Oui" et "Non".

#### **Décision et action (Feature Engineering) :**

- Créer une variable `Confort_Score` correspondant à la somme des 5 variables binaires.
- Supprimer ensuite les 5 colonnes individuelles.
- Traiter `Confort_Score` comme une variable numérique et lui appliquer un `StandardScaler`.

## **4.2. Variable nominale Quartier**

#### **Observations :**

- Impact très fort sur le loyer.
- Les quartiers comme *Rohero* et *Kiriri* affichent des médianes supérieures à 2M BIF.
- Les quartiers comme *Buyenzi* ou *Kamenge* sont en dessous de 800k BIF.
- Certains quartiers ont de très faibles effectifs (moins de 25 observations).

#### **Décision et action (Data Prep) :**

- Regrouper les classes rares : tout quartier ayant moins de 25 occurrences sera renommé en une catégorie unique *Autres*.
- Encoder cette variable avec `OneHotEncoder` en utilisant `handle_unknown='ignore'`.

## **5. Valeurs manquantes**

#### **Observations :**

- Les valeurs manquantes sont réparties uniformément sur 25 lignes, soit environ 4.9% du dataset.
- Elles touchent les mêmes observations sur plusieurs features.
- Aucun schéma net ne suggère une dépendance évidente à une variable observée.

#### **Décision et action (Data Prep) :**

- Le mécanisme semble compatible avec une hypothèse MCAR (Missing Completely At Random), sans exclure une vérification plus fine en phase de préparation.
- Les valeurs manquantes pourront être imputées ultérieurement dans un pipeline dédié, afin de conserver le maximum d'observations et d'éviter toute fuite de données.
- Une stratégie robuste consistera à imputer les variables numériques par la médiane et les variables catégorielles par la modalité la plus fréquente, exclusivement sur le jeu d'entraînement.

## **6. Résumé : plan d'action final pour les phases 3 et 4**

| Variable / Groupe                      | Action (Phase 3 et 4)                                                     |
|----------------------------------------|---------------------------------------------------------------------------|
| <code>LoyerMensuel_BIF</code> (Target) | Filtrer les valeurs égales à 2.5M, puis appliquer <code>np.log1p</code> . |

| Variable / Groupe                                           | Action (Phase 3 et 4)                                                                                 |
|-------------------------------------------------------------|-------------------------------------------------------------------------------------------------------|
| Chambres                                                    | Conserver au départ, puis valider son apport par comparaison des modèles avec et sans cette variable. |
| Superficie_m2,<br>DistanceRoute_m,<br>AgeMaison             | <b>Conserver.</b> Appliquer StandardScaler dans le pipeline.                                          |
| Salon,<br>SalleDeBainInterieure,<br>Parking, Meuble, Jardin | Créer Confort_Score, puis supprimer les 5 colonnes individuelles.                                     |
| Quartier                                                    | Regrouper les classes rares (moins de 25 occurrences) en Autres, puis appliquer OneHotEncoder.        |
| Valeurs manquantes (NaN)                                    | Imputer plus tard dans un pipeline, en calculant les statistiques uniquement sur le train.            |
| IdentifiantMaison                                           | <b>Supprimer</b> cette colonne, conformément au cahier des charges.                                   |

## 7. Conclusion

L'EDA a permis d'identifier les variables les plus contributives à la prédiction du loyer, de mettre en évidence plusieurs redondances, et de définir une stratégie de prétraitement robuste. Les choix retenus – nettoyage des outliers artificiels, transformation logarithmique de la cible, agrégation des modalités rares, gestion différée des valeurs manquantes et création d'un score de confort – fournissent une base cohérente pour construire un pipeline Machine Learning fiable et exploitable en production. La variable Chambres est conservée à ce stade, car son utilité réelle devra être tranchée empiriquement selon le modèle retenu.